Trabajo Práctico Especial

Fundamentos de la Ciencia de Datos - 2026

Grupo : 10

Integrantes :
Bianchi Valentina
Taboada Manuel Agustin
Martin Lenti Joan

Profesor ayudante asignado:
Rosana Cepeda

1. Introducción

Para este trabajo práctico especial se realizó un análisis detallado del conjunto de datos de la Encuesta Nacional de Factores de Riesgo (ENFR) 2018. Mediante una investigación de recursos online, determinamos que se trata del cuarto relevamiento de este tipo realizado en Argentina, llevado a cabo de manera conjunta por el INDEC y la Secretaría de Gobierno de Salud entre septiembre y diciembre de 2018.

El objetivo de esta encuesta fue recopilar información sobre los factores de riesgo y la prevalencia de las principales enfermedades no transmisibles (ENT) en la población adulta de Argentina. El conjunto de datos está estructurado a nivel individual e incluye dimensiones sociodemográficas (edad, género, nivel educativo, ingresos), hábitos de vida (consumo de alcohol, tabaco, alimentación y actividad física) y registros tanto autorreportados como de mediciones físicas y bioquímicas objetivas (tensión arterial, glucemia, colesterol e índice de masa corporal).

A lo largo de este trabajo se llevará a cabo un análisis exploratorio de los datos del dataset, limpieza y tratamiento de datos faltantes, y también un planteo de hipótesis y su validación. Dado el gran volumen de variables, este trabajo enfocará su análisis en unas dimensiones específicas, recortando el dataset en función al interés del grupo 10.

2. Análisis exploratorio de los datos (Notebook: 2 y 2.3)

La base original de datos, suministrada en un archivo .txt, cuenta con un total de 29224 registros encuestados y 287 variables. Se hizo un barrido completo de todas las variables junto con los datos recopilados imprimiendolas para conocerlas mejor y en nuestra exploración inicial (inspeccionando el archivo en crudo), pudimos observar lo siguiente:

- Primeramente nos dimos cuenta que el archivo sigue una cierta estructura que no es la tradicional. Las columnas no están separadas con comas, si no que usan el caracter de barra vertical (|) como delimitador. Es un detalle clave para cuando se haga la lectura del dataset en Python.

- A simple vista también se nota que casi todas las variables categóricas se encuentran codificadas de manera numérica. Por ejemplo, en lugar de decir "Buenos Aires" o "Secundario Completo", el dataset presenta números (ej: 1, 2, 3). Esto nos confirma la necesidad de utilizar el Manual de Uso de la Base de Datos del INDEC (Diccionario de Datos) para decodificar y entender qué representa cada valor durante el análisis.

- Se observa una gran cantidad de campos vacíos estructurales, representados por delimitadores consecutivos (|||). Esto indica una fuerte presencia de valores nulos (NaN), lo cual es lógico en encuestas de salto. Esto requerirá un tratamiento cuidadoso en la fase de limpieza.

- En varias filas se observan números recurrentes atípicos, como 98, 99, 999 ó 9999. Estos valores representan respuestas de tipo "No Sabe" o "No Contesta" (NS/NC) u "Otras respuestas", según el Manual de Uso. Esta observación es muy importante para la limpieza de datos, ya que si estas variables numéricas se analizan estadísticamente sin ser filtradas previamente, estos códigos actuarán como "outliers" (valores atípicos) falsos y distorsionarán drásticamente los promedios.

2.1 Definición de dimensiones de interés (Notebook: sección 2.1)

Después de haber analizado la documentación y la estructura del dataset decidimos enfocar nuestro trabajo en las siguientes dimensiones temáticas ya que creemos que representan bastante bien lo que se buscaba al recopilar esta información:

- Alimentación (Al)
- Colesterol (Co)
- Hipertensión (Ha)

De esta manera, las próximas etapas de limpieza y análisis de hipótesis se realizará filtrando el dataset original para trabajar exclusivamente con las variables de los bloques elegidos.

Se plantea también un cuarto dataset con variables necesarias para atacar las hipótesis planteadas en el enunciado, ya que para algunas de esas hipótesis no contábamos con la información necesaria en nuestros grupos previamente definidos

Adicionalmente se encontraron variables fuera de los grupos seleccionados pero que están relacionadas con algunos de nuestros grupos, tales como Mediciones antropométricas (MA) y Mediciones bioquímicas (MQ) entre otras, el primer grupo mencionado está relacionado con el grupo de Hipertensión (HA) mientras que el otro se relaciona con el grupo Colesterol(CO). Estos datos adicionales no serán considerados para nuestro análisis debido a que su incorporación vuelve nuestro trabajo demasiado extenso.

2.2 Descripcion y clasificacion de las variables (Notebook: sección 2.2)

Este proceso lo hacemos previo a las operaciones de limpieza ya que primero necesitamos conocer nuestras dimensiones de trabajo y el dataset.

Las filas que fueron marcadas en rojo se eliminaron ya que se considera que no aportan algo significativo para nuestros análisis.

Alimentación (AL)		
bial01	habitualmente agrega sal a las comidas durante cocción	Cualitativa nominal: respuestas representan categorías sin orden
bial02	frecuencia con que agrega sal a los alimentos una vez cocidos	Cualitativa ordinal: categorías con un orden
bial03	cantidad de días por semana que come fruta	cuantitativa discreta: cuenta días de la semana que come fruta
bial03_99	auxiliar de no responde para bial03	
bial04	cantidad de porciones de fruta que consume por dia	cuantitativa continua: representa una cantidad que puede expresarse con fracciones
bial04_99	auxiliar de no respuesta para bial04	
bial05	cantidad de días por semana que consume verduras	cuantitativa discreta: cuenta días enteros
bial05_99	auxiliar de no responde	
bial06	cantidad de porciones de verduras que consume por dia	cuantitativa continua: puede tomar valores fraccionarios
bial06_99	auxiliar de no responde	
bial07	cual es la razón principal por la que no consume más porciones de fruta o verdura	cualitativa nominal: categorías sin un orden aparente
bial08	categoriza qué tan saludable es su alimentación	cualitativa ordinal: categorías con orden bien definido
bial09	razón por la que considera que su dieta es poco saludable	cualitativa nominal: categorías sin orden aparente
bial10	está de acuerdo o no con el aumento del impuesto a	cualitativa nominal: respuesta de si o no

	bebidas azucaradas	únicamente
promedio_fv_diario	resume el consumo diario de verduras y frutas	cuantitativa continua: expresa un promedio
consumo_fv	derivada del consumo de frutas y verduras, consume al menos cinco porciones de fruta o verdura diarias	cualitativa nominal: respuestas de si o no
barreras_fyv	barreras para el consumo de fyv	cualitativa nominal: múltiples categorías de respuesta sin orden
tipo_dieta_razones	razones por las que considera que su dieta no es saludable	cualitativa nominal: categorías sin orden

tabla 1. Se muestran todas las variables relacionadas al bloque de alimentos.

Colesterol (CO)		
bico01	alguna vez se midió el colesterol	cualitativa nominal
bico02	última vez que se midió el colesterol	cualitativa ordinal
bico03	alguna vez un profesional de la salud le dijo que tenia colesterol alto	cualitativa nominal
bico04	en las últimas semanas practico algun tratamiento para mantener controlado el colesterol (indicado por profesional)	cualitativa nominal
bico05_01	hace algún tratamiento con dieta, ejercicio o reducción de peso	cualitativa nominal
bico05_02	hace algún tratamiento con medicamentos	cualitativa nominal
control_colesterol	medición de colesterol alguna vez por autorreporte en varones >= 35 y mujeres >=45	cualitativa nominal
prevalencia_colesterol	prevalencia de colesterol elevado por autorreporte	cualitativa nominal

tabla 2. Se muestran todas las variables relacionadas al bloque de colesterol.

Hipertensión (HA)		
biha01	alguna vez se ha tomado la presión arterial	cualitativa nominal
biha02	cuándo fue la última vez que se tomo la presion arterial	cualitativa ordinal
biha03	cuántas veces un profesional de la salud le indico que tenia presion alta	cualitativa ordinal
biha04	en las últimas 2 semanas hizo tratamiento para controlar la presión indicado por un profesional	cualitativa nominal
biha05_01	hace algún tratamiento con dieta, ejercicio o reducción de peso	cualitativa nominal
biha05_02	hace algún tratamiento con medicamentos	cualitativa nominal
biha06	cuantas pastillas que debe tomar por dia para controlar la presión arterial	cuantitativa discreta: representa un conteo, toma valores enteros
biha06_99	auxiliar de no contesta	
biha07	alguna vez se olvida de tomar la medicación	cualitativa nominal
biha08	si usted se siente bien, deja de tomar la medicación	cualitativa nominal
biha09	si usted se siente mal, deja de tomar la medicación	cualitativa nominal
biha10	frecuencia de consumo de las pastillas para controlar la presión en la última semana	cualitativa ordinal: se expresa en categorías pero hay un orden claro
biha11	cuantas pastillas para controlar la presión NO tomó en la última semana	cuantitativa discreta
biha11_99	auxiliar de no contesta	
biha12	excluyendo tomarse la	cualitativa nominal

	pastilla, hay alguna razón por la que usted vaya a hacerse control relacionado a la presión	
biha13	a qué lugar va habitualmente para hacerse controles relacionados a la presión	cualitativa nominal
biha14	cuando va a ese lugar lo atiende siempre el mismo profesional	cualitativa nominal
biha15	el profesional que lo atiende en ese lugar conoce su historial médico	cualitativa nominal
control_hipertension	medición de la presión por un profesional en los últimos 2 años por autorreporte	cualitativa nominal
prevalencia_hipertension	prevalencia de presión elevada por autorreporte	cualitativa nominal

tabla 3. Se muestran todas las variables relacionadas al bloque de hipertensión.

Dataset de hipótesis (HIP)		
HIPÓTESIS A		
bial03	días por semana que consume fruta	cuantitativa discreta: cuenta cantidad de días
bial04	porciones de fruta consumidas por día	cuantitativa continua
bial05	días por semana que consume verduras	cuantitativa discreta
bial06	porciones de verduras consumidas por día	cuantitativa continua
HIPÓTESIS B		
nivel_actividad_fisica	nivel de actividad física de la persona	cualitativa ordinal
imc_bima	imc calculado a partir de peso y talla medidos	cuantitativa continua
HIPÓTESIS C		
imc_bima	imc calculado a partir de	cuantitativa continua

	peso y talla medidos	
promedio_sistolica	presión arterial sistólica promedio de las mediciones	cuantitativa continua
bima13	perímetro de cintura medido en centímetros	cuantitativa continua
bhch04	edad en años cumplidos	cuantitativa discreta
bimq05	valor de glucemia capilar medido en mg/dl	cuantitativa continua

tabla 4. Se muestran todas las variables relacionadas a las hipótesis planteadas en el enunciado propuesto por la cátedra.

3. Implementación de operaciones de limpieza de la base (Notebook: sección 2)

Para empezar con la limpieza de nuestro Dataset lo que hicimos fue copiar el mismo en otra variable para no trabajar sobre el original.Además, de la copia que hicimos solamente nos quedamos con las columnas de interés para achicar el conjunto de datos con el que se trabaja.

Cómo decisión de limpieza de la Base de Datos, se decidió implementar la eliminación de filas duplicadas. Esto se tuvo en cuenta ya que si las filas eran exactamente iguales puede haber sido porque se encuestó una misma persona más de una vez.

Por otro lado, se reemplazaron los outliers (valores atípicos), valores vacíos y saltos de línea detectados en el análisis por el valor nulo por defecto de pandas (NaN), con el fin de que no afecten en los promedios estadísticos.

Luego se implementó código para eliminar las columnas cuyo nombres terminan en ‘’_99’’ (bial03_99, bial04_99, bial05_99, bial06_99, biha06_99 y biha11_99), puesto que cada una de ellas es un indicador asociado a una única variable, y toma el valor 99 únicamente cuando la persona encuestada respondió “No sabe / No contesta” a esa pregunta; en esos casos la variable original queda vacía. Al verificar los datos, comprobamos que en el 100% de esas filas la variable original ya es nula, por lo que la columna _99 no aporta información nueva.

También se decidió borrar las filas, de los bloques por separado, donde solamente se tenían todos las respuestas null, ya que no aportarían información a la estadística del conjunto.

4. Planteo de hipótesis y resolución

En esta parte nos enfocaremos en plantear algunas hipótesis sobre las variables (una univariada, una bivariada y otra multivariada) y analizarlas para saber si son correctos los planteos o no.

4.1 Hipótesis univariada (Notebook: sección 3.1)

Hipótesis: Más de la mitad de los hipertensos medicados se olvida alguna vez de tomar la medicación.
Justificación: Tomar la medicación todos los días puede resultar difícil para quienes tienen una enfermedad crónica como la hipertensión. Olvidarse de tomar la pastilla es algo muy común según varios estudios históricos, por eso esperamos que más de la mitad de los hipertensos medicados reconozca haberse olvidado alguna vez de tomarla.
Variable involucrada: biha07 (variable cualitativa nominal dicotómica)
Variable de filtro: biha05_02
H0: p<= 0,5
H1: p > 0,5

4.1.1¿Cómo llevamos adelante este análisis? (Notebook: 3.1.1 a 3.1.9)

Para esta hipótesis, se trabajó con el bloque de hipertensión. La pregunta sobre el olvido de la medicación solo se responde cuando la persona hace tratamiento con medicamentos, por lo que se aplicó un filtro para obtener la población que responde a eso.

Como técnica principal se aplicó el test z, ya que,al ser una variable dicotómica, se compara una proporción contra un valor fijo, unilateral a la derecha ($\alpha = 0,05$), para saber si el porcentaje de quienes se olvidan es realmente mayor al 50 % o si esa diferencia podría deberse al azar de la muestra verificando previamente que $n \cdot p_0$ y $n \cdot (1 - p_0)$ para saber si la muestra sea lo bastante grande para que el test sea confiable.

Luego, el resultado se confirmó con el test binomial y se calculó un intervalo de confianza del 95 % (método de Wilson). Por último, para comprobar que la conclusión no depende de haber elegido una pregunta en particular, hicimos lo mismo con otras dos preguntas de adherencia (biha08 y biha09) y con un indicador que las combina, inspirado en la escala de Morisky-Green.

4.1.2 Conclusión

Como resultado, se obtuvo que el 26,5 % de los hipertensos medicados reconoce haberse olvidado alguna vez de tomar la medicación (intervalo de confianza del 95 %: de 25,3 % a 27,7 %). Como ese valor está muy por debajo del

50 %, ambos tests dan un p-valor cercano a 1 y **no se rechaza H0**: los datos no respaldan que más de la mitad se olvide.

4.2 Hipótesis bivariada (Notebook: sección 3.2)

Hipótesis: Quienes agregan sal con más frecuencia a la comida cocida tienen mayor prevalencia de hipertensión.
Justificación: Como el consumo excesivo de sodio puede incrementar la presión arterial (y causar hipertensión), agregar sal a la comida ya cocida suele ser un indicador de un patrón de comportamiento de alto consumo de sodio. Quien tiene este hábito generalmente consume más sal que quien se limita a usar sal solo durante la preparación de los alimentos.
Variable involucrada: bial02 y prevalencia_hipertension
Variable de filtro: Ninguna.
H0: la prevalencia de hipertensión es independiente de la frecuencia con que se agrega sal a la comida cocida.
H1:existe asociación entre ambas.

4.2.1¿Cómo llevamos adelante este análisis? (Notebook: 3.2.1 a 3.2.9)

Lo primero fue ver qué pasaba a simple vista. Calculamos qué porcentaje de personas con hipertensión hay en cada grupo (quienes agregan sal siempre o casi siempre, raras veces o nunca) y lo graficamos con intervalos de confianza, que muestran el margen de error de cada porcentaje. Ya en el gráfico se notaba que los grupos no eran iguales.

Para confirmar que esa diferencia no era casualidad usamos el test chi-cuadrado, que compara lo que observamos con lo que veríamos si el uso de sal y la hipertensión no tuvieran ninguna relación. Para que el test sea confiable, cada grupo necesita tener suficientes casos, y acá se cumplió de sobra. El resultado fue que sí existe una asociación ($\chi^2 = 224{,}3$; $p < 0{,}001$). Pero con tantos casos, el test detecta como significativa hasta una diferencia muy pequeña, así que medimos qué tan fuerte es la relación con la V de Cramér, que dio 0,09, es decir, una asociación muy débil. Además, miramos los residuos ajustados para ubicar en qué grupos se concentra la diferencia.

Como chi-cuadrado solo dice si hay una relación, nos faltaba saber en qué sentido va la misma. Como nuestra hipótesis esperaba más hipertensión en quienes agregan sal siempre, hicimos un test específico que comparara a ese grupo con el de quienes nunca la agregan. La respuesta fue la contraria a la esperada: quienes nunca agregan sal tienen más hipertensión (41,3 %) que quienes siempre lo hacen (30,5 %).

Como dudábamos de ese resultado, nos preguntamos si la edad lo estaba distorsionando. Los más jóvenes agregan más sal (17,7 % contra 7,2 % en mayores de 65) y tienen menos hipertensión, lo que podría esconder la relación real. Por eso repetimos la comparación dentro de cada grupo de edad, y la diferencia se mantuvo: desde los 35 años, el grupo que nunca agrega sal sigue teniendo la mayor prevalencia de hipertensión.

4.2.2 Conclusión

Cómo conclusión, **se rechaza H_0**, ya que hay una asociación entre la frecuencia de uso de sal y la hipertensión, aunque muy débil, y va en sentido contrario al planteado en la hipótesis. La explicación más probable es una causalidad inversa: la encuesta registra si la persona ya fue diagnosticada, y a quienes tienen hipertensión se les indica reducir la sal. Es decir, no sería que evitar la sal causa hipertensión, sino que tener hipertensión lleva a dejar de agregar sal. Como la encuesta mide ambas cosas en el mismo momento, no permite saber qué ocurrió primero; para eso haría falta un estudio que siga a las personas en el tiempo, o comparar sólo a quienes no tienen diagnóstico previo.

4.3 Hipótesis multivariada (Notebook: sección 3.3)

Hipótesis: La probabilidad de colesterol elevado es mayor en quienes consumen menos frutas y verduras y consideran poco saludable su alimentación.
Justificación: Una alimentación rica en frutas y verduras, por su aporte de fibra, se asocia con mejores niveles de colesterol, mientras que una dieta poco saludable es un factor de riesgo de colesterol elevado. Además, la percepción que las personas tienen de su propia alimentación puede reflejar sus hábitos reales. Por eso esperamos que quienes comen menos frutas y verduras y consideran poco saludable su dieta presenten mayor probabilidad de colesterol elevado.
Variable involucrada: bial08, promedio_fv_diario, prevalencia_colesterol
Variable de filtro: Ninguna
H0: el consumo diario de frutas y verduras y la percepción de lo saludable de la alimentación no se asocian con la probabilidad de colesterol elevado (los coeficientes de ambas variables son iguales a cero).
H1:al menos una de las dos variables se asocia con la probabilidad de colesterol elevado (al menos un coeficiente es distinto de cero).

4.3.1¿Cómo llevamos adelante este análisis? (Notebook: 3.3.1 a 3.3.9)

Para esta hipótesis se trabajó con personas de las que se conoce cuántas porciones de frutas y verduras consumen por día, cómo consideran su alimentación (agrupada en “saludable” y “poco o nada saludable”) y si tienen colesterol elevado. Además se usó la edad, que ya forma parte del dataset de hipótesis.

Primero miramos cada variable por separado. La percepción de la dieta mostró la relación esperada: el colesterol elevado pasa de 29,6 % entre quienes consideran su dieta muy saludable a 40,8 % entre quienes la consideran nada saludable. Con las frutas y verduras no apareció lo esperado: en el cuartil que más consume la prevalencia fue algo mayor (32,4 %) que en el que menos consume (30,1 %). Al cruzar ambas variables, como plantea la hipótesis, vimos que en los dos niveles de consumo quienes consideran poco saludable su dieta tienen más colesterol elevado.

Antes de armar el modelo comprobamos que las dos variables no estuvieran tan relacionadas entre sí como para confundirlo (VIF = 1,07, muy por debajo del límite de 5). Luego ajustamos una regresión logística con el colesterol elevado como variable a explicar y las dos variables de la hipótesis como explicativas. Elegimos este modelo porque la respuesta es de tipo sí/no y porque permite medir el efecto de cada variable manteniendo fija la otra. Con el test de razón de verosimilitud evaluamos H0, que plantea que ambos coeficientes son cero. Dio LR = 47,6 y $p \approx 5 \cdot 10^{-11}$, por lo que se rechaza H0: al menos una de las variables se asocia con el colesterol elevado. Sin embargo, el pseudo R^2 de McFadden fue de 0,002, así que el modelo explica muy poco de las diferencias entre las personas.

Para interpretar cada variable usamos odds ratios, que comparan las chances de tener colesterol elevado entre dos situaciones (un valor de 1 significa que no hay diferencia). Quienes consideran poco saludable su dieta tienen un 28 % más de odds de colesterol elevado (OR = 1,28). Por cada porción diaria adicional de frutas y verduras, las odds son un 4 % mayores (OR = 1,04), es decir, lo contrario a lo esperado.

Como la edad influye tanto en el colesterol como en los hábitos, repetimos el modelo ajustando por edad. El efecto de la percepción de la dieta se hizo más fuerte (OR = 1,54) y el de frutas y verduras siguió apenas por encima de 1. Un nuevo test confirmó que las dos variables siguen aportando información una vez controlada la edad. Los resultados de ambos modelos se resumieron en un gráfico de odds ratios con sus intervalos, donde la línea en 1 marca el “sin efecto”. Por último, graficamos la probabilidad de colesterol elevado que estima el modelo según las porciones diarias: quienes consideran poco saludable su dieta quedan siempre unos 5 puntos porcentuales por encima.

4.3.2 Conclusión

Conclusión: **se rechaza H0**, pero la hipótesis se sostiene solo en parte. La percepción de una dieta poco saludable se asocia con más colesterol elevado, como era esperado, aunque de forma débil. Con las frutas y verduras no se observó el efecto esperado. Una posible explicación es la causalidad inversa: a quienes ya tienen el colesterol alto se les recomienda comer más frutas y verduras, y como la encuesta mide todo en el mismo momento, no permite saber qué ocurrió primero.

4.4 Hipótesis de enunciado univariada (Notebook: sección 4.1)

Hipótesis: El consumo diario de frutas y verduras en la población adulta argentina es inferior a las 5 porciones diarias recomendadas por la OMS.
H0: μ >= 5 porciones
H1: μ < 5 porciones

4.4.1¿Cómo llevamos adelante este análisis? (Notebook: 4.1.1 a 4.1.8)

Para esta hipótesis se trabajó con el promedio diario de porciones de frutas y verduras de 28.471 personas. En promedio consumen 2,07 porciones por día (con mediana de 1,64), y solo el 6,2 % llega a las 5 que recomienda la OMS. Para entender de dónde sale ese promedio miramos también sus componentes: en promedio se come fruta 4 días por semana y verdura 4,6 días, y los días que se consumen se comen entre 1 y 2 porciones. Lo graficamos con un histograma, que marca la recomendación de la OMS, la media y la mediana, con un diagrama de caja y con barras que muestran cuántos días por semana se consume cada alimento. En los gráficos se ve que la gran mayoría de las personas queda muy por debajo de las 5 porciones.

Como queremos comparar el promedio de una sola variable numérica con un valor fijo, usamos el test t para una muestra, unilateral a la izquierda (α = 0,05). Este test supone que el promedio se comporta de forma aproximadamente normal, así que revisamos la forma de los datos con un gráfico QQ-plot y con el test de Kolmogorov-Smirnov. La distribución no es normal: está muy cargada hacia valores bajos y tiene una cola larga hacia la derecha (asimetría 2,55). Sin embargo, con casi 28.500 casos el teorema central del límite asegura que el promedio sí se comporta como una normal, por lo que el test es válido. Para confirmarlo repetimos el análisis con el test de Wilcoxon, que no necesita normalidad y compara la mediana con 5.

Notas:

- **promedio_fv_diario (de df_AL)** como variable del test. Es la variable que calcula el INDEC: (días de fruta × porciones + días de verdura × porciones) / 7. Expresa el consumo diario, que es lo que se compara contra las 5 porciones de la OMS. No se calcula a mano a partir de bial03 a bial06 porque, a quien come 0 días, la encuesta no le pregunta las porciones y la variable queda vacía. Calcularlo así exigiría limpiar esos nulos.
- **bial03 y bial05 (de df_HIPOTESIS)** como contexto descriptivo. Muestran si el bajo consumo se debe a que se come pocos días o pocas porciones por día.

4.4.2 Conclusión

Como conclusión, ambos tests **rechazan H0** con un p-valor prácticamente nulo (t = −289,3). El intervalo de confianza del 95 % para la media va de 2,05 a 2,09 porciones, muy lejos de 5. El d de Cohen fue de −1,71, un efecto grande, así que la diferencia con la recomendación no solo es estadísticamente significativa sino también importante en la práctica. Se concluye que el consumo diario de frutas y verduras es inferior a las 5 porciones recomendadas.

4.5 Hipótesis de enunciado bivariada (Notebook: sección 4.2)

Hipótesis: El índice de masa corporal, calculado a partir de la medición física de peso y talla (del paso 2) cambia según el nivel de actividad física de las personas
H0: el IMC medio es igual en todos los niveles de actividad
H1: al menos un nivel tiene un IMC medio distinto.

4.5.1¿Cómo llevamos adelante este análisis? (Notebook: 4.2.1 a 4.2.7)

Para esta hipótesis se trabajó con 16.282 personas a las que se les midió peso y talla, separadas según su nivel de actividad física: bajo (7.674), medio (5.840) y alto (2.768). A simple vista el IMC baja a medida que aumenta la actividad: el promedio es 28,99 en el nivel bajo, 27,83 en el medio y 26,95 en el alto. Lo mostramos con diagramas de caja que marcan los límites de sobrepeso (25) y obesidad (30), con las medias de cada grupo y su intervalo de confianza, y con los histogramas de los tres grupos superpuestos.

Como queremos comparar el promedio de una variable numérica entre tres grupos, la técnica natural es el ANOVA de un factor. Antes de aplicarlo revisamos sus supuestos. Con el test de Kolmogorov-Smirnov y los gráficos Q-Q vimos que el IMC no es normal en ningún grupo (tiene cola hacia la derecha), aunque con grupos tan grandes eso afecta poco al ANOVA. Con el test de Levene vimos que las varianzas tampoco son iguales: el nivel bajo es el más disperso. Por eso, además del ANOVA, aplicamos el test de Kruskal-Wallis, que no necesita normalidad ni varianzas iguales y compara la distribución completa del IMC entre los grupos.

Notas:

- Las dos variables salen de **df_HIPOTESIS**. En la base, nivel_actividad_fisica está codificada al revés (1 = Alto, 3 = Bajo). Por eso se le ponen etiquetas y se ordena Bajo → Medio → Alto.

4.5.2 Conclusión

Conclusión: **se rechaza H_0** y se **confirma la hipótesis**. El IMC difiere según el nivel de actividad física (Kruskal-Wallis, p < 0,001; resultado confirmado por el ANOVA). Las comparaciones de a pares muestran que los tres niveles difieren entre

sí, y el IMC disminuye a medida que aumenta la actividad: 28,99 en el nivel bajo, 27,83 en el medio y 26,95 en el alto. Se eligió Kruskal-Wallis como test principal porque no se cumplen los supuestos de normalidad ni de homogeneidad de varianzas. Aunque la diferencia es estadísticamente significativa, el efecto es pequeño: el nivel de actividad física explica menos del 2% de la variación del IMC (eta² = 0,017), que depende también de otros factores como la alimentación, la edad y la genética. Por tratarse de un estudio transversal, no puede afirmarse si el sedentarismo aumenta el IMC o si un IMC elevado dificulta la actividad física.

4.6 Hipótesis de enunciado multivariada (Notebook: sección 4.3)

Hipótesis: Existe una relación lineal entre el índice de masa corporal, la presión sistólica, el perímetro de la cintura, la edad y los valores de glucemia capilar registrada en ayunas.
H0: ninguna de las cuatro variables tiene relación lineal con la glucemia (los cuatro coeficientes son cero)
H1: al menos una variable tiene relación lineal con la glucemia.

4.6.1¿Cómo llevamos adelante este análisis? (Notebook: 4.3.1 a 4.3.11)

Para esta hipótesis se trabajó con las 4.976 personas que tienen las cinco mediciones. Primero miramos cada variable y cómo se relacionan entre sí con una matriz de diagramas de dispersión, y después calculamos las correlaciones de a pares. Usamos la correlación de Pearson, que mide relaciones lineales, y como control la de Spearman, que no necesita que los datos sean normales. Las dos dieron resultados casi iguales, y las resumimos en un mapa de calor.

Todas las correlaciones fueron positivas y significativas, pero de fuerza muy distinta. La más fuerte es entre IMC y cintura (r = 0,80), lo cual es lógico porque ambas miden la grasa corporal. Le sigue la relación entre edad y presión sistólica (r = 0,45). En cambio, la glucemia se relaciona sólo débilmente con las demás (entre 0,15 y 0,21).

Para ver la relación de todas juntas armamos una regresión lineal múltiple, con la glucemia como variable a explicar y las otras cuatro como explicativas. Elegimos la glucemia porque el IMC, la cintura, la presión y la edad son factores de riesgo conocidos de diabetes. Estandarizamos las explicativas, de modo que cada coeficiente indica cuántos mg/dl cambia la glucemia por cada desvío estándar de esa variable, y así se pueden comparar entre sí. El test F global dio F = 73,4 y $p \approx 1 \cdot 10^{-60}$, por lo que con esto se podría rechazar H0, ya que nos indica que existe una relación lineal entre la glucemia y las demás variables. Pero el R^2 fue de apenas 0,056, es decir, el modelo explica solo el 6 % de las diferencias de glucemia entre las personas.

Mirando cada variable, la cintura (3,93 mg/dl por desvío), la edad (2,90) y la presión sistólica (1,50) resultaron significativas, mientras que el IMC no (1,25; p = 0,083). Sospechamos que esto se debía a que el IMC y la cintura aportan casi la misma información. El VIF quedó por debajo de 5 (2,83 y 2,99), así que no es un problema grave, pero al sacar la cintura del modelo el IMC pasó a ser significativo (4,23 mg/dl por desvío) y el R^2 apenas bajó (de 0,056 a 0,050). Es decir, el IMC sí se relaciona con la glucemia, pero cuando está la cintura en el modelo ella "se lleva" ese efecto.

Por último, revisamos los residuos del modelo, que son las diferencias entre la glucemia real y la predicha. El gráfico Q-Q y el test de Kolmogorov-Smirnov muestran que no son normales: hay personas con glucemias muy altas que el modelo no logra predecir (asimetría 2,31). Con 4.976 casos los coeficientes y el test F siguen siendo confiables, pero esto confirma que la relación lineal solo describe una parte pequeña del comportamiento de la glucemia.

4.6.2 Conclusión

Para finalizar con el análisis, concluimos que **se rechaza H_0** y se **confirma la hipótesis**. Existe una relación lineal entre las cinco variables, fuerte entre IMC y cintura y moderada entre edad y presión, pero débil con la glucemia. La glucemia tiende a ser algo mayor en personas con más cintura, edad y más presión, aunque estas variables explican muy poco de ella. Además los residuos del modelo no siguen una distribución normal, debido a un grupo de personas con glucemias muy elevadas, lo que constituye una limitación del modelo.

5. Conclusiones finales

El objetivo de este trabajo fue analizar la Encuesta Nacional de Factores de Riesgo 2018 a partir de tres dimensiones relacionadas con las enfermedades no transmisibles: alimentación, colesterol e hipertensión. Después de explorar y limpiar los datos, planteamos y validamos seis hipótesis, tres propias y tres del enunciado, que nos ayudaron a tener una imagen clara de los hábitos de la población adulta y de los límites de este tipo de datos.

El hallazgo más contundente es el de la alimentación. El consumo de frutas y verduras está muy por debajo de lo recomendado: en promedio se consumen unas 2 porciones diarias en lugar de 5, y solo el 6 % de las personas alcanza la recomendación de la OMS. Es el único resultado del trabajo con un efecto grande, y muestra un factor de riesgo extendido en casi toda la población. También encontramos que el IMC es menor en las personas

más activas y que la glucemia tiende a ser mayor en quienes tienen más cintura, edad y más presión.

Por otro lado, varias de nuestras hipótesis propias no se cumplieron como esperábamos, y eso también fue un aprendizaje. Menos de un tercio de los hipertensos medicados reconoce olvidarse de la medicación, lejos de la mitad que suponíamos. Además, quienes nunca agregan sal y quienes comen más frutas y verduras presentaron más hipertensión y más colesterol respectivamente, que el resto. Lo interpretamos como causalidad inversa: como la encuesta registra diagnósticos ya conocidos y mide todo en el mismo momento, es probable que muchas personas hayan cambiado sus hábitos después de enterarse de su enfermedad. Por eso, con estos datos se pueden describir asociaciones, pero no afirmar qué causa qué.

Por último, un patrón que se repitió en casi todas las hipótesis fue que, con muestras de miles de personas, los tests detectaron como significativas diferencias que en la práctica son pequeñas. Medidas como la V de Cramér, el η^2, el pseudo R^2 o el R^2 pudieron mostrar que el uso de sal, la percepción de la dieta, la actividad física y las variables físicas explican muy poco por sí solas, lo que nos enseñó a no quedarnos solo con el p-valor y a mirar siempre el tamaño del efecto. A esto se suma que muchas variables son autorreportadas y que no usamos los ponderadores de la encuesta, así que los resultados describen a la muestra y no son una estimación exacta de toda la población.

Bibliografía

- Manual de Uso de la Base de Datos ENFR 2018 - INDEC https://www.studocu.com/es-ar/document/universidad-siglo-21/modelos-de-simulacion/manual-de-uso-de-la-base-de-datos-enfr-2018-indec/146885260?sid=e2775f0b-f2f4-49ad-b0d8-bfe788e5b8eb1791663300

- Organización Mundial de la Salud (2026). Alimentación saludable. https://www.who.int/es/news-room/fact-sheets/detail/healthy-diet